

Informatică aplicată în ingineria industrială – anul I

Analiza și prelucrarea imaginilor – laborator
miercuri 13.01.2027, 16:00–18:00 · sală de stabilit

Lucrarea 13. Învățarea profundă pentru inspecție: clasificarea pieselor OK/NOK și detecția defectelor

Conținutul pachetului

p. 2–4 Îndrumar de laborator – Analiza și prelucrarea imaginilor (sursa: p. 43–45)

Lucrarea 13. Învățarea profundă pentru inspecție: clasificarea pieselor OK/NOK și detecția defectelor

Durata: 2 ore · Locul: laboratorul de informatică aplicată – FIMIM (standul de viziune) · Curs: cap. 14 (rețele neuronale convoluționale, integrarea sistemelor de viziune)

Norme specifice de securitate și sănătate în muncă (NSSM)

- ▲ Calculatoarele și standul de viziune se pornesc numai după verificarea cablurilor de alimentare; nu se deschid carcasele și nu se lucrează cu mâinile ude.
- ▲ Sursele de iluminare LED nu se privesc direct de aproape; inelul LED și fundalul luminos se opresc când nu sunt folosite.
- ▲ Camera și obiectivul se manipulează fără a atinge lentila și senzorul; capacul de protecție se montează la terminarea lucrării.
- ▲ Cablurile USB/Ethernet se așază astfel încât să nu poată fi agățate; nu se consumă lichide lângă calculatoare și stand.

13.1. Scopul lucrării

Cunoașterea structurii unei rețele neuronale convoluționale, antrenarea prin transfer learning a unui clasificator OK/NOK pe un set mic de imagini de piese, aplicarea unui model preantrenat de detecție a obiectelor și evaluarea performanței cu matricea de confuzie, precizia și sensibilitatea.

13.2. Noțiuni teoretice

O rețea neuronală convoluțională (CNN) învață singură filtrele (nucleele de convoluție) care extrag trăsăturile utile: primele straturi detectează muchii și texturi, straturile profunde – părți de obiecte și defecte. Un strat convoluțional cu N_f filtre de $K \times K$ pe o intrare cu C_{in} canale are parametrii și dimensiunea ieșirii (pas S , bordare P):

$$N_{param} = (K \cdot K \cdot C_{in} + 1) \cdot N_f \quad (13.1)$$

$$W_{ies} = \frac{W - K + 2 \cdot P}{S} + 1 \quad (13.2)$$




Fig. 13.1. Rețea convoluțională pentru clasificarea OK/NOK și matricea de confuzie pe setul de test

Prin transfer learning se pornește de la o rețea antrenată pe milioane de imagini și se reantrenează doar ultimele straturi pe câteva sute de imagini ale pieselor proprii. Performanța se evaluează pe un set de test separat. Cu TP defecte detectate corect, FN defecte ratate, FP piese bune respinse și TN piese bune acceptate:

$$P = \frac{TP}{TP + FP} \quad (13.3)$$

$$R = \frac{TP}{TP + FN} \quad (13.4)$$

$$F_1 = \frac{2 \cdot P \cdot R}{P + R} \quad (13.5)$$

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (13.6)$$

În controlul calității, defectele ratate (FN) sunt de obicei mai grave decât rebuturile false (FP), de aceea pragul de decizie se alege pentru o sensibilitate R mare. Detecția de obiecte (de exemplu, modelele YOLO) dă pentru fiecare obiect clasa, o casetă de încadrare și un scor de încredere.

```
from ultralytics import YOLO
m = YOLO("yolov8n-cls.pt") # model preantrenat de clasificare
m.train(data="piese_ok_nok", epochs=20, imgsz=224) # foldere train/ și val/ cu OK/ și NOK/
r = m("piesa_noua.png")[0]; print(r.names[r.probs.top1], float(r.probs.top1conf))
det = YOLO("yolov8n.pt")("banda.png")[0]; print(det.bboxes.xyxy, det.bboxes.cls)
```

13.3. Aparatură și echipamente

- Set de imagini de piese OK și NOK (≈ 200 pentru antrenare, 200 pentru test), achiziționat pe standul de viziune sau set public de defecte industriale
- PC cu Python, PyTorch și Ultralytics (rulare pe procesor sau pe placa grafică, dacă există)

13.4. Modul de lucru

1. Se organizează imaginile în foldere de antrenare, validare și test, pe clase OK și NOK.
2. Se antrenează clasificatorul prin transfer learning pentru 10–20 de epoci; se notează acuratețea de validare.
3. Se evaluează modelul pe setul de test și se completează matricea de confuzie (Tabelul 13.1).
4. Se variază pragul de decizie și se observă compromisul precizie – sensibilitate.
5. Se aplică un model preantrenat de detecție pe o imagine cu mai multe obiecte și se compară cu rezultatele metodelor clasice din lucrările 7–9.

13.5. Determinări

Tabelul 13.1. Evaluarea clasificatorului

Prag	TP	FN	FP	TN	P	R	F1
0,3							
0,5							
0,7							

13.6. Prelucrarea datelor

Exemplu rezolvat – primul strat convoluțional. Pentru intrarea $224 \times 224 \times 3$, cu 64 de filtre 3×3 , pas 1 și bordare 1:

$$N_{\text{param}} = (3 \cdot 3 \cdot 3 + 1) \cdot 64 = 1792 \quad (13.7)$$

$$W_{\text{ies}} = \frac{224 - 3 + 2}{1} + 1 = 224 \quad (13.8)$$

Exemplu rezolvat – evaluare. Pe 200 de piese de test (100 OK, 100 NOK), matricea din Fig. 13.1 dă TP = 92, FN = 8, FP = 6, TN = 94:

$$P = \frac{92}{92 + 6} = 0,939 \quad (13.9)$$

$$R = \frac{92}{92 + 8} = 0,920 \quad (13.10)$$

$$F_1 = \frac{2 \cdot 0,939 \cdot 0,920}{0,939 + 0,920} = 0,929 \quad (13.11)$$

$$\text{Acc} = \frac{92 + 94}{200} = 0,93 \quad (13.12)$$

Modelul ratează 8 % din piesele defecte. Dacă pragul de decizie se coboară, sensibilitatea crește (mai puține defecte ratate), dar crește și numărul pieselor bune respinse. Alegerea pragului este o decizie economică și de calitate, nu doar tehnică.

13.7. Interpretarea rezultatelor

- Care este acuratețea pe setul de test? Este apropiată de cea de validare?
- Ce tip de eroare (FN sau FP) este mai grav pentru piesele studiate? Ce prag alegeți?
- Ce avantaje și dezavantaje are învățarea profundă față de metodele clasice (prag, morfologie, analiza obiectelor)?

13.8. Relevanță practică

Clasificarea și detecția cu rețele neuronale sunt folosite astăzi pentru defectele greu de descris prin reguli: suduri, suprafețe texturate, piese turnate, textile, alimente, citirea textului în condiții dificile. Camerele inteligente și calculatoarele industriale cu acceleratoare rulează modelele direct pe linia de producție; setul de imagini etichetate devine un activ important al fabricii.

13.9. Întrebări de verificare

1. Ce este un strat convoluțional și ce învață el?
2. Ce este transfer learning și de ce este util în industrie?
3. Definiți precizia, sensibilitatea și scorul F1.
4. De ce setul de test trebuie să fie separat de cel de antrenare?
5. Cum se alege pragul de decizie al unui clasificator OK/NOK?